

SK플래닛 빅데이터분석가 10기

기업협업 프로젝트 OTT 고객 이탈 예측

2026.04.28

팀 이름: 애플사이다비니거

멘토: 박병선

멘티: 권동근 김광일 김나현 박인겸 허대수

CONTENTS

발표 순서

01

프로젝트 개요

이탈 예측 문제를 정의, 본 프로젝트를 수행하는 목적을 소개

02

데이터 소개

사용한 데이터의 구성, 주요 변수, 분석 대상 기간 설명

03

데이터 EDA 및 전처리

데이터 분포와 이상치를 확인하고, 전처리 방향을 정리합니다.

04

베이스라인 모델링

원본 데이터 기반의 초기 모델링과 기본 성능 확인

05

파생변수 생성

이탈 예측에 유의미할 수 있는 행동 및 요금제 관련 변수 생성

06

개선 (2차) 모델링 및 성능 비교

이탈 예측에 유의미할 수 있는 행동 및 요금제 관련 변수 생성

07

향후 보완 방향

중간발표 이후 추가로 개선할 점과 다음 단계 계획을 제시



박병선 멘토님

하나밖에없는우리멘토님



권동근 (동동이)

EDA
파생변수 생성, 모델링



김나현 (차나핑)

EDA, 파생변수, 모델링



김광일 (박광일)

EDA
파생변수 생성
수학 선생님



박인겸 (김인겸)

발표, PPT제작, EDA
어미새



허대수 (대수햄)

분석 설계
든든한 지원군



01. 프로젝트 개요

주제 Remind

시청행동 데이터 기반 OTT 고객 이탈 예측

01. 프로젝트 개요

주제 선정 이유



이탈방지가 왜 중요한가?

OTT 산업은 다양한 플랫폼 간 경쟁이 심화
신규 가입자 확보보다 기존 고객 유지가 더 중요한 요소
즉 고객 이탈(Churn)은 직접적인 매출 감소로 이어짐



이탈 방지 행동 특징?

OTT 서비스는 구독 기반 모델, 이탈이 반복적 발생
이탈 직전 고객은 특정한 행동 패턴을 보일 수 있음
이를 사전에 탐지하면 전략으로 이탈 방지 제고 가능



데이터 축적

OTT 플랫폼은 시청이력 등의 행동 데이터를 축적
인구통계학 정보, 프로모션 정보에 대한 높은 설명력 확보

Now, Let's Define Our Approach

View_History	간단설명
FK PK USER_NUM	부여된 유저번호
FK PK MOVIE_NUM	콘텐츠 고유 식별번호
DURATION	해당 콘텐츠가 재생된 시간(분)
PK WATCH_DAY	시청일자 (YYYYMMDD)
PK WATCH_SEQ	하루에 시청한 순서

Movie_Master	간단설명
PK MOVIE_NUM	콘텐츠 고유 식별번호
TITLE	콘텐츠 제목
RELEASE_MONTH	콘텐츠가 OTT 플랫폼에 등록된 날짜

User_Mapping	간단설명
FK USER_KEY	암호화된 유저키
PK USER_NUM	부여된 유저번호

Membership	간단설명
PK USER_KEY	128자리로 암호화된 User Key
product_cd	가입 상품 코드
amount	실제 결제 금액(원화/달러 혼재)
concurrent_streams	가능한 동시 시청 수
billing_method	결제 수단
promotion_yn	100원 프로모션 참여 여부
is_churn_prevented	해지 방어 적립 여부 해지 신청 시 포인트 증정 후 해지 철회
repurchase	재결제 여부
payment_device	결제 기기(PC, Android, iOS 등)
is_user_verified	본인인증 여부 (미인증 시 성별/연령 부정확)
gender	성별(남성/여성/알 수 없음)
age	연령대 (5년 단위 표기)
reg_date	구독 단위기간 시작 날짜
reg_hour	가입한 시간대
end_date	구독 만료 날짜

이름

Description.xlsx

Membership.csv

Movie_Master.csv

User_Mapping.csv

View_History.csv

02. 데이터 소개

데이터 소개

02. 데이터 소개

데이터 소개

Membership.csv						
USER_KEY	product_cd	amount	concurrent_streams	plan	billing_method	promotion_yn
19d327b1bb7e2b88..	pk_1489	13900	4	Premium	134	
User_Mapping.csv						
USER_KEY	USER_NUM					
19d327b1bb7e2b88..	239	View_History.csv				
		USER_NUM	MOVIE_NUM	DURATION	WATCH_DAY	WATCH_SEQ
		239	12690	95	20210322	2
		Movie_Master.csv				
		MOVIE_NUM	TITLE	RELEASE_MONTH		
		12690	존윅(2014)	202008		

03. 데이터 EDA 및 전처리

EDA 들어가기 전에...

Membership	(TYPE)	예시	설명
USER_KEY	VARCHAR	19d327b1...	SHA-512 방식(128자리 16진수)로 암호화된 USER KEY. Primary Key 역할 수행중
product_cd	VARCHAR	pk_1489	가입 상품 코드
amount	FLOAT	13900	실결제 금액 (단위: 원화, 달러가 혼재되어 있음)
concurrent_streams	INT	4	동시 시청 가능 수. 1, 2, 4의 값을 가짐 (Basic/Standard/Premium)
billing_method	INT	134	결제 수단 (코드값)
promotion_yn	VARCHAR	O	100원 프로모션 참여 여부 (첫 달 100원, 둘째/셋째 달 50% 할인)
is_churn_prevented	VARCHAR	O	해지방어 적립 여부 (해지 신청 시 포인트 증정 후 해지 철회)
repurchase	VARCHAR	O	재결제 여부
payment_device	VARCHAR	android	결제 기기 (pc / android / ios / mobile / sstv / lgstv / ott / smarttv)
is_user_verified	VARCHAR	Y	본인인증 여부 (미인증 시 성별과 연령이 부정확함)
gender	VARCHAR	M	성별 (F / M / N)
age	INT	60	연령대, 5년 단위 표기 (예: 31~35세 → 35)
reg_date	DATETIME	2021-03-10	구독 단위기간의 시작
reg_hour	INT	17	가입한 시간대(Hour)
end_date	DATETIME	2021-04-10	구독 만료일. 취소 시 가입일로 치환

이걸 다 설명하는 것은
무리! 그리고 불필요!!!

필요한 EDA만 하겠음!!!

03. 데이터 EDA 및 전처리

EDA 들어가기 전에...

1. SK로부터 받을 수 있는 OTT 데이터이다.
2. 2021년 3월~4월에 100원딜이 존재했다.

이 조건들을 조합해 검색해보니...

1. sk로부터 받을 수 있는
 2. OTT 시청기록 데이터였으며
 3. 2021년 3월에서 4월 사이에 100원딜 프로모션이 존재했던
- 이러한 조건을 만족하는 OTT 서비스가 뭐가 있는지 찾아봐.

세 조건을 교차 검색해보겠습니다.

웹 검색됨 >

검색 결과를 종합하면, 세 조건을 동시에 만족하는 OTT 서비스를 확인할 수 있습니다.

결론: 웨이브(Wavve)

세 가지 조건 각각을 어떻게 만족하는지 정리하면 다음과 같습니다.



확신할 수는 없지만 'Wavve'라고 가정하고 진행하겠음!!!

데이터 소개

Membership.csv						
USER_KEY	product_cd	amount	concurrent_streams	plan	billing_method	promotion_yn
19d327b1bb7e2b88..	pk_1489	13900	4	Premium	134	
User_Mapping.csv						
USER_KEY	USER_NUM					
19d327b1bb7e2b88..	239	View_History.csv				
		USER_NUM	MOVIE_NUM	DURATION	WATCH_DAY	WATCH_SEQ
		239	12690	95	20210322	2
		Movie_Master.csv				
		MOVIE_NUM	TITLE	RELEASE_MONTH		
		12690	존윅(2014)	202008		



영화에 대한 상세 정보가 있으면
도움이 되겠는데?

유저들이 시청한 영화의 갯수(unique): 5171개

→ Wavve로부터 웹크롤링을!



Wavve에서의 라이선스가 만료된(계약기간이 끝난) 콘텐츠 존재

→ 2021년 03월 ~ 04월 사이의 데이터이기에, 현재(2026년) 누락된 영화 콘텐츠 존재



영화진흥위원회(KOBIS) api를 활용해 누락된 영화의 데이터 수집

→ 강의 초반에 실습으로 진행했던 영화진흥위원회 웹크롤링을 활용해보기



콘텐츠 제목
예) 장송의 프리렌





제목 별 고유코드
예) PRG_C6101_C6100000006904



Wavve api (Request URL)

https://apis.wavve.com/fz/vod/contents-detail/C6101_C610000000904?apikey=E5F3E0D3...



firstreleasedate: "2026-01-16"
firstreleaseyear: "2026"
genretext: "애니메이션"
genrevalue: "08"
programtitle: "장송의 프리렌"
seasontargetage: "15"
contentid: "C6101_C610000000904"
cpid: "C61"
creditendtime: "002411"
creditstarttime: "002231"
...

콘텐츠 제목
예) 범죄도시4

제목 별 고유코드 (movieCd)
예) 20240421

http://www.kobis.or.kr/kobisopenapi/webservice/rest/movie/
searchMovieInfo.json?key=0000&movieCd=20240421

KOBIS Open API (Request URL)

OPEN API

제공서비스

일별 박스오피스
주간/주말 박스오피스
공통코드 조회
영화목록
영화 상세정보
영화사목록
영화사 상세정보
영화인목록
영화인 상세정보

다운로드

튜토리얼

영화상세정보 조회 API 서비스

통합전산망에서 사용되는 영화상세정보를 영화코드를 통해 조회합니다.
REST/SOAP 방식 중 선택적으로 호출가능하며 REST 방식의 응답형식은 XML과 JSON을 지원합니다.(URI의 extension으로 구분)

1. REST 방식

- 기본 요청 URL : http://www.kobis.or.kr/kobisopenapi/webservice/rest/movie/searchMovieInfo.xml (또는 .json)
- 요청 parameter : 3번항의 요청 인터페이스 정보를 참조하여 GET 방식으로 호출

2. SOAP 방식

- 요청 URL : http://www.kobis.or.kr/kobisopenapi/webservice/soap/movie
- WSDL URL : http://www.kobis.or.kr/kobisopenapi/webservice/soap/movie?wsdl
- Operation : searchMovieInfo

3. 인터페이스


- 요청 인터페이스

요청 변수	값	설명
key	문자열(필수)	발급받은키 값을 입력합니다.
movieCd	문자열(필수)	영화코드를 지정합니다.

- 응답 구조

응답 필드	값	설명
movieCd	문자열	영화코드를 출력합니다.

movieCd: "20240421"
movieNm: "범죄도시4"
movieNmEn: "The Roundup: Punishment"
openDt: "20240424"
genreNm: "액션"
typeNm: "장편"
peopleNm: "허명행"
watchGradeNm: "청소년관람불가"
...



■ Wavve 크롤링
 ■ KOBIS 크롤링
 ■ 누락된 영화


수집된 영화 출처	수치
Wavve 크롤링	3778건 (73.06%)
KOBIS 크롤링	1158건 (22.39%)
누락(결측)	235건 (4.54%)



03. 데이터 EDA 및 전처리

OTT 이탈 모델링의 실질적 종속변수

→ Repurchase (1/0)



repurchase

O = 재결제 (11,931명, 65.62%)

X = 이탈 (6,252명, 34.38%)

원본 데이터에서 O/NaN으로 표기 → 전처리 시 O=1, NaN=0으로 변환


산출물 >>> DB분석, Function, 아키텍처 데이터 정의서 등.

03. 데이터 EDA 및 전처리

연령(age) 이상치 탐지 및 제거

전처리 근거

Wavve 최소 가입연령 14세 기준으로 0세~5세를 이상치 처리. 이후 Z-score 방법($|z| > 3$)으로 72세 이상 고연령 이상치를 추가 제거. 결측치 포함 총 221건 삭제(전체의 1.2%).




변수	age
분석 조건	10 이상
평균	33.93
표준편차	12.59
이상치 기준	$ z > 3$
하한값	-3.85
상한값	71.72
최소값	15.0
최대값	950.0
이상치 수	51
이상치 비율	0.28%
데이터 수	18013

03. 데이터 EDA 및 전처리

동시접속가능 인원 데이터 핸들링

- EDA, 이상치처리, 파생변수 생성




concurrent_streams

해석하면 동시시청자 수.
최대 동시시청자 수가..

1이면 Basic 요금제
2이면 Standard 요금제
4이면 Premium 요금제에 해당함

이에 3은 나올 수가 없는 수.
결측 포함 77건은 삭제처리



	베이직	스탠더드	프리미엄
이용요금	7900원	1만900원	1만3900원
동시접속	1명	2명	4명
화질지원	HD	FHD	UHD
이용기기	모바일+PC	모바일+PC +TV☆☆	모바일+PC +TV☆☆

파생변수 생성 (plans)

```

if concurrent_streams == 1:
    df["plans"] = "Basic"

elif concurrent_streams == 2:
    df["plans"] = "Standard"

else:
    df["plans"] = "Premium"
    
```


03. 데이터 EDA 및 전처리

분포 분석 및 이상치 처리

- 결제 금액

Distribution of Purchased Amount



amount

결제금액으로 원화(KRW)와 달러(USD)가 혼재되어 있는 상태임.

이유: iOS Appstore 결제 때문!

이상치 분포 분석 (달러 기준)

Z-score 방식 ($|z| > 3$, amount < 100)
 평균=11.25 표준편차=2.14
 이상치 수: 7개 (0.23%)
 이상치 amount 범위: 20.49 ~ 29.69

100원 프로모션


발동 조건: 본인인증 / 프로모션 이력 X

첫 달: 100원 (요금제 종류와 관계없이)
 둘째, 셋째 달: 50% 할인된 금액으로 유지 가능

03. 데이터 EDA 및 전처리

회사 카테고리 그룹화

- 결제 방법



payment_device

직접 리서치 해본 결과...

lgstv, sstv, smarttv, lgchplus는 SmartTV로,
ott, ott_cjhelloworld는 OTT로 치환.

나머지는 이상 없는 깔끔한 데이터

+) mobile은 웹브라우저에서 결제한 것.
iOS인지 Android인지 구별 불가능!

유료방송사들의 OTT 서비스

CJ헬로비전
'뷰잉'

viwing

실시간 채널 및 주문형비디오(VOD) 서비스
유튜브·넷플릭스 콘텐츠 제공
맞춤형 콘텐츠 추천 인공지능(AI) 기술 적용



03. 데이터 EDA 및 전처리

양극화 패턴과 장르별 차이

- 콘텐츠 완주율 분석

완주율

1. 사용자의 절반 이상이 영화를 완주하지 않음.
2. 애니메이션 가족 장르는 끝까지 보는 경향이 강하다.



03. 데이터 EDA 및 전처리

당일 취소 기록은 이상치 처리
- repurchase 기준과 맞지 않음!

USER_KEY	repurchase	reg_date	end_date	subscribed_days
a7aa34f124f7563608bf35be02f05a203c344cdf	O	2021-03-12	2021-03-12	0
28569cb6174f92f112476e7b931a3a670c4b2c	O	2021-03-04	2021-03-04	0
a7aa34f124f7563608bf35be02f05a203c344cdf	O	2021-03-01	2021-03-01	0
6f7b011c17ce027655f1bb3f0ec7a5206b2ada	O	2021-03-04	2021-03-04	0
f245052a7fb537302a3ac88613e3935718ef86c	O	2021-03-08	2021-03-08	0
96ea467029aa29b9b0701441896a972e77158	O	2021-03-03	2021-03-03	0
93fdcf03985edda8ecf7b8c272f6139a09231d29	O	2021-03-01	2021-03-01	0
3cb1abf74112c5a11545a913a5d39e8e2f2ce28	O	2021-03-10	2021-03-10	0
b547e87847685831ea4a5422532fd05edc4384	O	2021-03-08	2021-03-08	0
6f7b011c17ce027655f1bb3f0ec7a5206b2ada	O	2021-03-10	2021-03-10	0
a8831c07bdee26f98deca7a33e5a3f56218df4	O	2021-03-10	2021-03-10	0
becf3a7527c14159eb40b432b08a2719ae7eef	O	2021-03-11	2021-03-11	0
87cafab0e28f1209c989855736b726d90a4ed8	O	2021-03-01	2021-03-01	0
8546aab242085febbaaa9ecebc78dd352724c	O	2021-03-10	2021-03-10	0

subscribed_days 파생변수 생성

Registered date (구독 시작일) 과
 End date (구독 만료일)을 통해
 유저의 구독 유지 기간을 알 수 있음.


**subscribed_days가 0이면 당일 취소,
 그런데, repurchase?**

repurchase는 '정기결제 수단'으로 다음 달
 구독이 갱신된 경우에 (O) 처리가 되는 것.
 그런데, 당일 취소를 했는데, 구독 자동 갱신이?

정보력에 큰 훼손은 없으므로
 "정합성 위배" 사유로 제거처리 하였음

03. 데이터 EDA 및 전처리

요일별 시청 기록 차이



1개월 기준 요일별 시청 기록 (duration)

유저들의 1개월 동안 시청 이력을 요일별로 나타낸 것

- 단위는 분(min)
- 값의 범위가 달라 **Z-Score 표준화**로 통일
- 사용자 수를 기준으로 계산

토요일과 일요일에는
총 시청 시간과 평균 시청 시간이 높게 나타나는 경향!

평일과 비교했을 때 주말에는 사용자도 많음과 동시에,
사용자들이 꾸준히 길게 보는 것을 확인할 수 있음

+) 이를 통해 파생변수를 만들기는 무리가 있다고 판단.
하지만 흥미로운 인사이트여서 가져와보았음!


총 시청 시간 = 해당 요일에 시청된 영화 콘텐츠의 총 시간(단위: 분)

사용자 평균 시청 시간 = $\frac{\text{총 시청 시간}}{\text{해당 요일에 시청한 유저 수}}$


03. 데이터 EDA 및 전처리

성별과 나이의 관계는?

→ 교호작용 변수 도출



성별 × 연령대 교차표 (인증 고객만)



gender x age

wavve 인증 고객의 핵심 연령층은 20~30대 여성이 가장 많음을 확인.

전반적으로 여성 고객이 남성보다 多!
40대 이후로 급감하는 패턴을 보임

03. 데이터 EDA 및 전처리


성별, 나이, 그리고 재결제율까지

→ 재결제율도 유의미하게 높았을까?

장년층들은 구독의 유지가
매우 잘 되고 있는 모습
(재결제율이 70%대)

1020 Z세대들은
생각보다 재결제율이 낮았음.

하지만 前슬라이드에서는
젊은 층이 핵심 유저층!



10대와 20대 남성과 여성의 재결제율이 낮게 나오는 경향을 포착!
젊은 층의 이탈을 막는 프로모션을 진행 or 장년층의 꾸준한 구독을 유지하는 방향으로 프로모션을 진행

03. 데이터 EDA 및 전처리

플랜 별로 이탈률?

→ 플랜별로 이탈률이 어떻게 다르게 나타날까?


플랜 별 이탈률 (전체)	
베이직	32.7%
스탠다드	24.0%
프리미엄	44.6%

23% 차이!

플랜 별 이탈률 (프로모션 제외, 정가만!)	
베이직	29.8%
스탠다드	22.6%
프리미엄	21.6%

인사이트!


- 모든 면에서 프로모션을 적용했을 때 이탈률이 높게 나왔다.
- 스탠다드는 이탈률이 가장 낮았다 (TV 시청 가능성이 클 것으로 예상)
- 프리미엄 요금제가 가장 이탈률 차이가 컸다 (가격이 가장 큰 요인?)



03. 데이터 EDA 및 전처리

그렇다면 콘텐츠를 소비하는 행태는?

→ 영화를 보는 것과 충성도의 관계를 살펴보자



파생변수

is_new_movie

= $\frac{\text{21년 3월에 wavve에 들어온 영화를 시청한 수}}{\text{유저가 시청한 영화 갯수}}$

파레토 곡선으로 바라본 콘텐츠 시청 분포

Case 1. 인기작과 신작을 많이 보는 유저
 → 콘텐츠를 적극적으로 소비하는 부류
 → 이러한 콘텐츠의 공급이 적다면? 이탈 가능성 ▲

Case 2. 인기작과 신작을 적게 보는 유저
 → 적극적이지 못한 유저들
 → 사용률을 높이지 못한다면? 이탈 가능성 ▲▲

03. 데이터 EDA 및 전처리


그렇다면 이탈방지 정책을 적용했을때?



잠시만요!

지금 해지하시면 매주 업데이트 되는
다양한 영화와 해외 시리즈들을 더 이상 볼 수 없어요!

정말 해지하시겠어요?



이용권을 유지하면 감사의 의미로

10,000코인을 드려요.


코인 받고 다양한 최신 영화를 감상해 보시겠어요?

고객의 이탈을 막기 위한 정책: 코인(포인트) 제공하기

구독권을 유지한다면 일정 금액에 해당하는 코인(포인트)를 제공하며 고객의 이탈을 방지하는 정책이다.

그렇다면 이탈방지 정책을 적용했을때?

프로모션과 이탈방지 조합별 이탈률



프로모션이 적용되지 않은, 정가 가격 고입 고객의 경우

- 이탈방지 정책 적용 전후 이탈률이 거의 변화 없음
- 이탈방지 정책의 효과가 미미하여 추가 개입 효율 낮음

100원딜 등의 프로모션이 적용된 유저의 경우

- 이탈방지 정책 적용 시 이탈률 39.2% → 27.4%, 11.8%p의 강력한 감소 효과
- 가격 민감도가 높아 본격 결제 시점에서 이탈 위험이 큰 그룹
- 이탈방지 정책의 핵심 타겟 → 정책 집중 적용 필요

04. 베이스라인 모델링

베이스라인을 잡기 위한 기초 모델링

→ 말 그대로 베이스라인!

기초 모델링 데이터셋 Feature
amount
billing_method
concurrent_streams
promotion
is_churn_prevented
payment_deivce
is_user_verified
gender
age
reg_hour



종속변수 Y
repurchase (구독 이탈 했느냐, 안 했느냐)

베이스라인을 잡기 위한 기초 모델링

방법: 분류 (Classification)

사용할 모델: 로지스틱 회귀, 랜덤포레스트, Gradient Boosting

평가지표: Accuracy, F1-Score, ROC-AUC, PR-AUC

특이사항: 아무런 하이퍼파라미터도 넣지 않고, 최소한의 수정을 거친 채 돌려보았음.

베이스라인을 잡기 위한 기초 모델링

Baseline

모델	구분	Accuracy	F1-Score	ROC-AUC	PR-AUC
Logistic Regression	Train	0.6746	0.7975	0.6149	0.7332
	Test	0.6723	0.7957	0.6225	0.7454
RandomForest	Train	0.876	0.9095	0.9572	0.9778
	Test	0.6338	0.7389	0.6039	0.7216
Gradient Boosting	Train	0.6908	0.8023	0.6796	0.7884
	Test	0.6857	0.7973	0.6667	0.769

04. 베이스라인 모델링

평가 지표에 대한 타이틀

모델	구분	Accuracy	F1-Score	ROC-AUC	PR-AUC
Logistic Regression	Train	0.6746	0.7975	0.6149	0.7332
	Test	0.6723	0.7957	0.6225	0.7454

Q1. 왜 F1-score을 기준으로 잡은건가요?

재구매율 향상을 위해서는 단순 정답률보다 관리가 필요한 고객을 정확히 선별하는 것이 중요
 F1-Score는 Precision과 Recall을 함께 반영하므로, 예측의 정확성과 탐지 능력을 균형 있게 평가할 수 있음.

Q2. Accuracy와 AUC는 평가 과정에서 어떻게 활용했나요?

Accuracy는 데이터 불균형 상황에서 관리 대상 고객 선별 성능을 충분히 설명하기 어려워 최종 기준에서 제외함.
 AUC는 모델의 구분 능력을 확인하는 보조지표로 활용하였음.
 최종 모델은 F1-Score를 중심으로 선정하고, F1-Score와 AUC의 Train-Test 차이를 함께 확인해 과적합 여부를 판단하였음.


파생변수 만들어야
할 것 같지 않니?

이 정도면 되지 않나?



05. 파생변수 생성

요금제 관련 파생변수



is_basic

→ 7,900원

is_standard

→ 10,900원

is_premium

→ 13,900원

concurrent_streams(동시접속 가능)이
1이면 Basic, 2면 Standard, 4면 Premium

해당 파생변수를 만든 이유는?

- 우리가 관심 있는 정보는 이 유저가 어떤 요금제를 쓰는가.
- 그런데 이 정보는 본래 concurrent_streams라는 값으로 들어가 있음.
- 모델은 연속형 숫자로 오해할 수 있기 때문에 원핫인코딩 방식으로
- 이렇게 바꾸면 각 요금제가 독립적인 범주 변수로 분리!

05. 파생변수 생성

유저들의 시청 히스토리로부터의 파생변수

→ 시청시간과 횟수 등

USER_NUM	MOVIE_NUM	DURATION	WATCH_DAY	WATCH_SEQ
0	4243	1	20210314	1
0	4243	11	20210314	2
0	1860	101	20210319	1
0	2170	1	20210325	1
0	6031	100	20210326	1
0	2170	1	20210328	1
0	6031	100	20210328	2
0	12495	3	20210328	3
0	2170	92	20210328	4
1	10976	124	20210324	1
2	7541	1	20210310	1
2	40	1	20210321	1
2	13893	85	20210327	1

파생변수	간단설명
total_watch_duration	총 시청 시간(분)

파생변수	간단설명
watch_days_count	시청 일수

파생변수	간단설명
total_watch_count	총 시청 횟수 (분할시청 포함)
unique_movies	시청 고유 영화 수

05. 파생변수 생성

유저들의 시청 히스토리로부터의 파생변수

→ retention, recency 등

파생변수	간단설명
retention_w2	1주차 대비 2주차 시청 시간 비율
retention_w3	2주차 대비 3주차 시청 시간 비율
signup_to_first_watch	가입 후 첫 시청까지 걸린 일수
recency	마지막 시청일로부터 경과일
stream_watch_interaction	요금제 가격 대비 실제 사용량

활용 예시

이탈 가능성

retention_w2 = 0.8 → 1주차의 80%만 시청

일정한 패턴 유지

retention_w2 = 1.0 → 시청 시간 동일

충성 사용자

retention_w2 = 1.2 → 시청 시간 증가

recency란?

구독 단위기간(31일)을 기준으로

마지막 시청일이 구독으로부터 얼마나 남았는가?

예) 5일째 되는 날에 마지막으로 시청하고 한 번도 안 봤다면 recency = 26

개선된 모델링 (1)

파생변수들.....


Membership
amount
billing_method
concurrent_streams
promotion
is_churn_prevented
payment_deivce
is_user_verified
gender
age
reg_hour

Membership에서 파생
currency_type
is_promotional_price
is_night_signup
reg_weekday
is_same_day_cancel
duration_days
age_group
요금제
is_basic / is_standard / is_premium
신규 사용자 정착
signup_to_first_watch
recency

View_History에서 파생
total_watch_count
total_watch_duration
unique_movies
avg_duration
watch_days_count
has_watch_history
시청 활동성
active_days
avg_rewatch_ratio
watch_per_day
watch_density
binge_score
completion_rate

교호작용 변수
plan_promotion
stream_watch_interaction
new_popular_dependency
promo_churn
시청 패턴 & 선호도
avg_release_year
weekday_watch_ratio
genre_* (10개)
is_new_movie
주차별 지속성
dur_w1 / dur_w2 / dur_w3
retention_w2 / retention_w3

개선된 모델링 (1)



개선된 모델링 (2)

변수 1	변수2	corr
total_watch_count	watch_density	0.988
total_watch_count	watch_per_day	0.987
concurrent_streams	is_premium	0.931
unique_movies	watch_density	0.912
duration_days	is_same_day_cancel	-0.93
avg_duration	completion_rate	0.881

변수1	변수2	corr
total_watch_count	watch_days_count	0.849
total_watch_count	active_days	0.849
active_days	watch_density	0.838
avg_rewatch_ratio	binge_score	0.8210
promotion_yn	plan_promo	0.806
concurrent_streams	is_basic	-0.803

삭제 기준

1. 파생변수의 원본이 되는 변수 제거
2. 상대적으로 정보량이 적은 변수 제거
3. 분석가의 도메인 및 임의판단

상관계수가 높은 변수들 둘 중 한 개를 취사선택 하였음!

개선된 모델링 (3)

베이스라인 (1차)

모델	구분	Accurac	F1-Score	ROC-AUC	PR-AUC
Logistic Regression	Train	0.6746	0.7975	0.6149	0.7332
	Test	0.6723	0.7957	0.6225	0.7454
RandomForest	Train	0.876	0.9095	0.9572	0.9778
	Test	0.6338	0.7389	0.6039	0.7216
Gradient Boosting	Train	0.6908	0.8023	0.6796	0.7884
	Test	0.6857	0.7973	0.6667	0.769

파생변수 추가 (2차) + OPtuna 200회 튜닝

모델	구분	Accuracy	F1-Score	ROC-AUC	PR-AUC
Logistic Regression	Train	0.6877	0.8030	0.6446	0.7627
	Test	0.6948	0.8077	0.6487	0.7652
RandomForest	Train	0.7088	0.8191	0.7905	0.8787
	Test	0.6934	0.8104	0.6733	0.7811
Gradient Boosting	Train	0.7152	0.8216	0.7684	0.8587
	Test	0.6965	0.8107	0.6723	0.7785
ExtraTrees	Train	0.7144	0.8215	0.7908	0.8846
	Test	0.6965	0.8107	0.6688	0.7799
LightGBM	Train	0.6912	0.8092	0.6982	0.8081
	Test	0.6906	0.8092	0.6755	0.7810
CatBoost	Train	0.6969	0.8098	0.7075	0.8145
	Test	0.6965	0.8096	0.6785	0.7862

1.23% 증가

향후 계획

1. 모델 정밀도 및 재현율 최적화

- 2 : 1 비율의 불균형 데이터 (구독 유지 : 해지) 해소를 위한 샘플링 기법 적용
- 추가적인 파생변수 생성 및 다양한 실험 시도

2. 데이터 기반 시각화

- Tableau를 활용한 해지 위험군 대시보드 구축
- 이탈 전조 현상 대시보드화

3. LLM / RAG 활용

- 이탈 징후가 보이는 대상에 대해 맞춤형 해지 방어 시나리오 생성
- 고객별 시청 데이터 기반 RAG를 활용하여 해지 방어를 위한 개인별 맞춤 콘텐츠 제안

06. 개선 (2차) 모델링 및 성능 비교

기대 효과

1. 효율적 자원 배분을 통한 마케팅 비용 최적화

- 기존 유지 가능성이 높은 고객에 대한 불필요한 비용 최소화
- 해지 위험이 높은 대상에 집중하여 마케팅적인 효율 최적화

2. 사전 이탈 방지를 통한 매출 상승 기대

- 이미 이탈을 한 대상을 돌아오게 하는 게 주된 목표가 아닌 이탈 징후를 '사전에' 포착
- 이탈 전에 혜택이나 방지 대책을 세움으로써 이탈을 예방하고 이를 통한 매출 상승 기대

감사합니다